

Tabla 1 — Composicion del problema: matriz dataset / clase

Dataset	Procedencia / dominio	Clase	n proc.	Modalidades	Uso en el proyecto	Riesgo metodologico
BraTS 2021	Multicentrico (challenge BraTS)	Tumor (1)	580	T1 + T2	Entrenamiento (pool)	Aporta SOLO positivos -> clase ligada al dominio
UPENN-GBM	Hosp. Univ. Pensilvania (TCIA)	Tumor (1)	587	T1 + T2	Entrenamiento (pool); fue test externo	Aporta SOLO positivos; firma de intensidad muy marcada
IXI	3 hospitales de Londres (sanos)	Sano (0)	577	T1 + T2	Entrenamiento (pool)	Aporta SOLO negativos
NKI Rockland	Nathan Kline Institute (sanos)	Sano (0)	523	T1 + T2	Entrenamiento (pool); reequilibrio neg.	Aporta SOLO negativos
BTC_preop (OpenNeuro ds001226)	Ghent University Hospital (1 centro)	Tumor (1) y Sano (0)	36 (25/11)	T1-only	Validacion intra-dominio (unica medicion honesta)	n pequeno; T1-only

Resumen: ningun dataset del pool aporta las dos clases

	Tumor (1)	Sano (0)
Pool principal	BraTS, UPENN	IXI, NKI
Validacion honesta	BTC_preop (Ghent)	BTC_preop (Ghent)

Confusion clase<->dominio del 100%: $P(\text{tumor}|\text{BraTS})=P(\text{tumor}|\text{UPENN})=1$ y $P(\text{tumor}|\text{IXI})=P(\text{tumor}|\text{NKI})=0$. 'Detectar tumor' y 'reconocer el centro de origen' son indistinguibles en el pool.
Fuentes: data/processed/preprocessing_summary.json ; docs/audit/audit_leakage.json (label_equals_dataset).

Tabla 2 — Analisis progresivo de validez del rendimiento aparente (narrativa en cascada)

#	Regimen	Modelo / prueba	Particion	AUC	Sen	Spe	IC95%	Interpretacion	Validez
1	Pool multi-fuente (split aleatorio)	CNN 3D (2 canales)	test 340 (175+/165-)	0.99997	0.994	1.000	—	Rendimiento aparente casi perfecto	NO VALIDO (confound)
2	Pool multi-fuente	Tiny baseline LogReg (16 stats)	test 340 (train n=600)	1.000	—	—	—	Etiqueta decodificable sin red ni anatomia	NO VALIDO (atajo)
3	Pool multi-fuente	Tiny baseline RF	test 340	0.9989	—	—	—	Idem	NO VALIDO (atajo)
4	Identificabilidad de dominio	Clf dataset (intensidad, 4 clases)	test 340	acc 0.985	—	—	—	Centro de origen trivialmente separable (azar 0.25)	Evidencia confound
5	Identificabilidad de dominio	Clf dataset desde embeddings (4 cl.)	latente 96-d	acc 0.982	—	—	—	El latente de la CNN codifica procedencia	Evidencia confound
6	LODO A: BraTS+IXI -> UPENN+NKI	CNN 3D (2 canales)	test n=1110	0.6236	0.676	0.463	—	Degrada hacia el azar fuera de dominio	NO VALIDO (no generaliza)
7	LODO B: UPENN+NKI -> BraTS+IXI	CNN 3D (2 canales)	test n=1157	0.2012	0.010	0.965	—	Regla invertida / colapso de sensibilidad	NO VALIDO (no generaliza)
8	LODO A	Tiny baseline LogReg	held-out	0.9952	—	—	—	El atajo transfiere en una direccion	Evidencia confound
9	LODO B	Tiny baseline LogReg	held-out	0.3184	—	—	—	El atajo no transfiere en la otra	Evidencia confound
10	BTC_preop intra-dominio	CNN 3D (1 canal)	k-fold, n=36	0.4036	0.60	0.364	[0.213, 0.623]	Compatible con azar (IC cruza 0.5)	VALIDA (medicion honesta)
11	BTC_preop intra-dominio	Tiny baseline LogReg	k-fold, n=36	0.5491	—	—	[0.319, 0.788]	Compatible con azar	VALIDA (medicion honesta)
12	BTC_preop intra-dominio	Tiny baseline RF	k-fold, n=36	0.4055	—	—	[0.215, 0.616]	Compatible con azar	VALIDA (medicion honesta)
13	Embeddings intra-clase	LogReg: IXI vs NKI (ambos sanos)	n=1100	0.998	—	—	—	Separa cohortes dentro de una clase -> codifica origen	Evidencia confound

Rojo = aparentemente bueno pero NO valido (inflado por confound). Verde = medicion metodologicamente honesta (clase y dominio desacoplados). Amarillo = evidencia del confound.
Fuentes: outputs/evaluation/cnn3d_test_results.json ; lodo_{A,B}/cnn3d_test_results.json ; btc_intradomain/cnn_kfold_results.json ; docs/audit/{audit_leakage,audit_lodo,btc_intradomain_tinybaseline,embeddings_intraclass}.json