

**UNIVERSIDAD ALFONSO X EL SABIO**

**FACULTAD DE BUSINESS & TECH**

**GRADO EN INGENIERÍA MATEMÁTICA**




**TRABAJO DE FIN DE GRADO**

**Priorización automática de RM cerebral mediante aprendizaje profundo: análisis crítico del sesgo de dominio en datasets públicos multi-fuente**

**Ignacio Sánchez Calabrese**

**Junio de 2026**



# UNIVERSIDAD ALFONSO X EL SABIO

Facultad de Business & Tech

GRADO EN INGENIERÍA MATEMÁTICA

## Priorización automática de RM cerebral mediante aprendizaje profundo: análisis crítico del sesgo de dominio en datasets públicos multi-fuente

**ALUMNO:** Ignacio Sánchez Calabrese

**N.P.:** 145657

**TUTOR ACADÉMICO:** Jorge Calvo Martín

**FECHA DE PRESENTACIÓN:** Junio de 2026

### **BREVE DESCRIPCIÓN:**

La creciente carga asistencial en radiología motiva el desarrollo de sistemas de priorización (triaje) automática de las resonancias con hallazgos urgentes, como las masas tumorales. Este trabajo aborda la clasificación binaria tumor/no tumor en RM cerebral con una red convolucional 3D (CNN 3D) entrenada sobre datos públicos multi-fuente (BraTS, UPENN-GBM, IXI y NKI Rockland). El modelo alcanza un rendimiento casi perfecto ( $AUC = 0.9999$ ; sensibilidad 0.994; especificidad 1.000), pero una auditoría lo desmonta: un *baseline* trivial de intensidad, sin red neuronal, también logra  $AUC = 1.0000$ ; fuera de dominio (*leave-one-dataset-out*) el AUC cae a 0.6236 y 0.2012 (inversión de signo); y en una cohorte de un solo escáner la CNN rinde al azar ( $AUC = 0.4036$ ; IC95 % [0.21, 0.62]). El rendimiento aparente obedece a un *confound* dominio-clase (*shortcut learning*), no a detección clínica. Se discuten las condiciones para un triaje radiológico válido con datos públicos multi-fuente.

**FIRMA DEL DIRECTOR DEL TRABAJO    FIRMA DEL ALUMNO**

A mi madre que siempre ha estado conmigo apoyándome, aconsejándome y guiándome.

A mi padre que siempre ha confiado en mí.

A mis hermanos, por su apoyo incondicional.

A mi familia, por su cariño y confianza.

A Almu, por ser mi referente y por impulsarme con tu fuerza y tus ganas.

A mis amigos, por no dejarme caer y por estar siempre ahí.

A mis profesores, por su dedicación y por compartir su conocimiento conmigo.

Este trabajo es para todos vosotros, que me habéis ayudado a llegar hasta aquí.

# Índice general

|                                                                                                   |          |
|---------------------------------------------------------------------------------------------------|----------|
| <b>1. Introducción</b>                                                                            | <b>4</b> |
| 1.1. Contexto clínico y motivación . . . . .                                                      | 4        |
| 1.2. Planteamiento del problema . . . . .                                                         | 4        |
| 1.3. De la hipótesis clínica inicial a la auditoría metodológica del modelo . . . . .             | 4        |
| 1.4. Objetivos y contribuciones . . . . .                                                         | 4        |
| 1.5. Estructura de la memoria . . . . .                                                           | 4        |
| <b>2. Objetivos</b>                                                                               | <b>5</b> |
| 2.1. Objetivo general . . . . .                                                                   | 5        |
| 2.2. Objetivos específicos . . . . .                                                              | 5        |
| <b>3. Estado del arte</b>                                                                         | <b>6</b> |
| 3.1. Diagnóstico por imagen de masas tumorales intracraneales . . . . .                           | 6        |
| 3.2. RM cerebral y limitaciones del diagnóstico radiológico . . . . .                             | 6        |
| 3.3. Deep Learning en imagen médica . . . . .                                                     | 6        |
| 3.4. Deep Learning aplicado a RM cerebral: enfoques, datasets y retos de generalización . . . . . | 6        |
| 3.5. Sesgo de dominio, shortcut learning y fugas de información en Deep Learning médico . . . . . | 6        |
| 3.6. Sistemas de priorización/triaje en radiología . . . . .                                      | 6        |
| <b>4. Materiales y datos</b>                                                                      | <b>7</b> |
| 4.1. Datasets: BraTS, UPENN-GBM, IXI, NKI Rockland y BTC_preop . . . . .                          | 7        |
| 4.2. Definición de clases y etiquetado . . . . .                                                  | 7        |
| 4.3. Composición del problema: relación entre clase y dataset de origen . . . . .                 | 7        |
| 4.4. Selección de modalidades T1/T2 . . . . .                                                     | 7        |
| 4.5. Análisis exploratorio de los datos . . . . .                                                 | 7        |
| <b>5. Metodología</b>                                                                             | <b>8</b> |
| 5.1. Preprocesado homogéneo . . . . .                                                             | 8        |
| 5.2. Arquitectura del modelo CNN 3D . . . . .                                                     | 8        |
| 5.3. Función de pérdida, optimización e hiperparámetros . . . . .                                 | 8        |

|                                                                                              |           |
|----------------------------------------------------------------------------------------------|-----------|
| 5.4. Data augmentation . . . . .                                                             | 8         |
| 5.5. Estrategia de partición a nivel de sujeto . . . . .                                     | 8         |
| 5.6. Entorno computacional y herramientas . . . . .                                          | 8         |
| <b>6. Diseño experimental y protocolo de validación</b>                                      | <b>9</b>  |
| 6.1. Métricas de evaluación y análisis operativo . . . . .                                   | 9         |
| 6.2. Validación interna sobre el pool multi-fuente . . . . .                                 | 9         |
| 6.3. Protocolo de auditoría de validez experimental . . . . .                                | 9         |
| 6.4. Baseline trivial sobre estadísticos de intensidad . . . . .                             | 9         |
| 6.5. Validación cruzada por dominio leave-one-dataset-out . . . . .                          | 9         |
| 6.6. Validación intra-dominio BTC_preop . . . . .                                            | 9         |
| 6.7. Análisis del espacio latente e interpretabilidad . . . . .                              | 9         |
| <b>7. Resultados: análisis progresivo de validez del rendimiento aparente</b>                | <b>10</b> |
| 7.1. Rendimiento aparente en el pool multi-fuente . . . . .                                  | 10        |
| 7.2. Decodificabilidad trivial de la etiqueta . . . . .                                      | 10        |
| 7.3. Identificabilidad del dominio . . . . .                                                 | 10        |
| 7.4. Generalización fuera de dominio LODO . . . . .                                          | 10        |
| 7.5. Validación intra-dominio BTC_preop . . . . .                                            | 10        |
| 7.6. Evidencia en el espacio latente y mapas de atención . . . . .                           | 10        |
| 7.7. Síntesis consolidada de resultados . . . . .                                            | 10        |
| <b>8. Discusión</b>                                                                          | <b>11</b> |
| 8.1. Interpretación: confound estructural dominio-clase . . . . .                            | 11        |
| 8.2. Por qué las métricas casi perfectas no son evidencia clínica . . . . .                  | 11        |
| 8.3. Viabilidad y condiciones para un triaje radiológico válido . . . . .                    | 11        |
| 8.4. Comparación con la literatura: shortcut learning, dataset bias y domain shift . . . . . | 11        |
| 8.5. Validez metodológica y reproducibilidad . . . . .                                       | 11        |
| 8.6. Implicaciones para el diseño de estudios con datos públicos multi-fuente                | 11        |
| <b>9. Conclusiones</b>                                                                       | <b>12</b> |
| <b>10. Limitaciones y líneas futuras</b>                                                     | <b>13</b> |
| 10.1. Limitaciones del estudio . . . . .                                                     | 13        |
| 10.2. Propuestas de mejora y líneas futuras . . . . .                                        | 13        |
| <b>A. Detalle de preprocesado y configuraciones</b>                                          | <b>14</b> |
| <b>B. Tabla maestra de resultados y detalle por fold</b>                                     | <b>15</b> |
| <b>C. Figuras adicionales</b>                                                                | <b>16</b> |
| <b>D. Reproducibilidad: comandos, seeds y entorno</b>                                        | <b>17</b> |

---

## Introducción

---

- 1.1 Contexto clínico y motivación
- 1.2 Planteamiento del problema
- 1.3 De la hipótesis clínica inicial a la auditoría metodológica del modelo
- 1.4 Objetivos y contribuciones
- 1.5 Estructura de la memoria

---

## Objetivos

---

### 2.1 Objetivo general

### 2.2 Objetivos específicos

---

## Estado del arte

---

- 3.1 Diagnóstico por imagen de masas tumorales intracraneales
- 3.2 RM cerebral y limitaciones del diagnóstico radiológico
- 3.3 Deep Learning en imagen médica
- 3.4 Deep Learning aplicado a RM cerebral: enfoques, datasets y retos de generalización
- 3.5 Sesgo de dominio, shortcut learning y fugas de información en Deep Learning médico
- 3.6 Sistemas de priorización/triaje en radiología



---

## Materiales y datos

---

- 4.1 Datasets: BraTS, UPENN-GBM, IXI, NKI Rockland y BTC\_preop
- 4.2 Definición de clases y etiquetado
- 4.3 Composición del problema: relación entre clase y dataset de origen
- 4.4 Selección de modalidades T1/T2
- 4.5 Análisis exploratorio de los datos

---

## Metodología

---

- 5.1 Preprocesado homogéneo
- 5.2 Arquitectura del modelo CNN 3D
- 5.3 Función de pérdida, optimización e hiperparámetros
- 5.4 Data augmentation
- 5.5 Estrategia de partición a nivel de sujeto
- 5.6 Entorno computacional y herramientas

---

## **Diseño experimental y protocolo de validación**

---

- 6.1 Métricas de evaluación y análisis operativo
- 6.2 Validación interna sobre el pool multi-fuente
- 6.3 Protocolo de auditoría de validez experimental
- 6.4 Baseline trivial sobre estadísticos de intensidad
- 6.5 Validación cruzada por dominio leave-one-dataset-out
- 6.6 Validación intra-dominio BTC\_preop
- 6.7 Análisis del espacio latente e interpretabilidad

---

## Resultados: análisis progresivo de validez del rendimiento aparente

---

- 7.1 Rendimiento aparente en el pool multi-fuente
- 7.2 Decodificabilidad trivial de la etiqueta
- 7.3 Identificabilidad del dominio
- 7.4 Generalización fuera de dominio LODO
- 7.5 Validación intra-dominio BTC\_preop
- 7.6 Evidencia en el espacio latente y mapas de atención
- 7.7 Síntesis consolidada de resultados

---

## Discusión

---

- 8.1 Interpretación: confound estructural dominio-clase
- 8.2 Por qué las métricas casi perfectas no son evidencia clínica
- 8.3 Viabilidad y condiciones para un triaje radiológico válido
- 8.4 Comparación con la literatura: shortcut learning, dataset bias y domain shift
- 8.5 Validez metodológica y reproducibilidad
- 8.6 Implicaciones para el diseño de estudios con datos públicos multi-fuente

---

## Conclusiones

---

---

## Limitaciones y líneas futuras

---

### 10.1 Limitaciones del estudio

### 10.2 Propuestas de mejora y líneas futuras

---

## **Detalle de preprocesado y configuraciones**

---



---

## **Tabla maestra de resultados y detalle por fold**

---

---

## Figuras adicionales

---

---

## **Reproducibilidad: comandos, seeds y entorno**

---

---

## Índice de figuras

---

---

## Índice de tablas

---